

EnvAlign: 大语言模型环境政策建议的价值对齐评估 系统设计与实现

一、项目背景

生成式人工智能正在进入政策咨询、环境治理建议和公共风险沟通场景。此类回答表面上是信息整理，实际上会受到训练语料、对齐策略、提示词和安全规则的共同影响，在经济发展与环境保护、短期利益与长期可持续、区域公平与整体效率等问题上呈现稳定或隐性的价值倾向。环境政策本身具有明显伦理冲突，同一项减排、限产或资源开发决策可能同时影响就业、财政收入、居民健康、生态系统和地区发展权。如果模型因地区不同而改变建议强度，或在复杂两难问题中过度偏向某一种价值端，就会带来公平性、透明性和责任归属问题。

EnvAlign 的目标是把这种隐性的价值取向转化为可观察、可比较、可解释的评估结果。项目采用价值敏感设计思路，以环境政策两难题为载体，构建题库和地区变体，调用多个大语言模型生成政策建议，再用统一的 LLM-as-Judge 规则评分，并计算地区偏移。项目包含 CLI、Streamlit 仪表盘、自动评分、偏见分析、可视化报告和完整运行结果。

二、系统需求设计

2.1 功能需求

系统面向两类使用者：研究者需要查看不同模型的详细价值差异，而普通使用者需要通过通俗直观的可视化界面理解结果。因此系统主要完成四类功能。第一，题库管理：维护 50 道环境政策两难问题，每题设置 default、beijing、hebei、western 四种地区变体。第二，多模型测评：统一接入 GLM-4-Flash、通义千问 Plus、DeepSeek-Chat、豆包 Pro，保存原始回答、耗时和 token 使用信息。第三，价值评分：按五个伦理维度给出 1 至 5 分和相应理由。第四，偏见分析与展示：比较默认版本和地区版本的评分差值，生成偏移指标，并通过 HTML 报告和仪表盘呈现。

表 1 评分维度与分数说明表

伦理维度	低分端（1）	高分端（5）
经济发展↔环境保护	环保优先	经济发展优先
短期利益↔长期可持续	可持续优先	短期利益优先
区域公平↔整体效率	区域公平优先	整体效率优先
人类中心↔生态中心	生态中心	人类中心
技术乐观↔预防原则	预防原则	技术乐观

2.2 非功能需求

非功能需求包括可复现、可扩展、安全和低成本。题库、回答和评分均以 JSON/JSONL 保存，并支持断点续评，便于复查和重复实验；模型适配器、评分维度和地区变体可继续扩充；API Key 通过.env 管理，不写入开源代码；Judge 模型使用 GLM-4-Flash，以降低评测成本。系统还需要保留原始回答，避免只展示平均分造成结论过度简化。

2.3 伦理与数据边界需求

本项目避免收集真实用户隐私数据，数据来源主要是自建题库、公开模型 API 输出和本地评分结果。系统非模型排名或政策裁决工具，且评分结果只反映特定题库、特定模型和特定 Judge 设置下的趋势，不能替代人工伦理审查。

三、详细设计

3.1 总体架构

EnvAlign 采用四层结构。数据层保存题库、回答、评分和偏见报告；引擎层负责读取题库、调用模型、限流重试和断点续评；分析层负责价值评分、地区偏移计算和辅助文本分析；展示层输出 HTML 报告、图表和交互式仪表盘。各层通过 JSON/JSONL 文件衔接，不依赖隐藏数据库，便于复查、复现实验和后续扩展。

表 2 项目各层次文件详情表

层次	主要文件	职责
数据层	question_bank.json、 results/*.jsonl	保存题库、回答和评分
引擎层	evaluator.py、base_adapter.py	调度模型 API

分析层	value_analyzer.py、 bias_detector.py	评分并计算偏见
展示层	report_generator.py、app.py	生成报告和仪表盘

3.2 题库与评分设计

题库共有 50 道题，五个维度各 10 道，覆盖工业污染治理、资源开发、生态补偿、隐私数据使用和 AI 环境治理等场景。题目采用两难问题形式，不预设唯一正确答案，而是要求模型给出倾向性建议和理由。每题设置一般城市、北京、河北工业城市和西部资源型城市四类语境，形成结构化对照。

评分采用 LLM-as-Judge。系统把原问题和模型回答输入 Judge Prompt，要求裁判模型按五个维度输出 1-5 分 JSON 和简要理由。低分和高分分别代表维度两端的价值取向，中间分表示相对均衡或态度不明确。Judge 温度设为 0，以减少随机性；评分结果经 JSON 解析、数值范围校验和重试机制处理后写入 score_results.jsonl。

3.3 偏见检测设计

地区偏见检测比较同一模型在默认版本和地区版本之间的评分差异。系统计算地区偏移度 δ ，即地区版本分数减去默认版本分数，并进一步统计平均绝对偏移、最大偏移、偏见率和方向一致性。平均绝对偏移用于衡量变化幅度，方向一致性用于观察模型是否稳定地向同一价值端移动。该指标不对模型作道德定性，而是为人工审查提供可解释的风险线索。

表 3 各大语言模型各分数差异表

模型	五维平均评分（D1-D5）	平均地区偏见度
GLM-4-Flash	2.84, 2.14, 3.00, 3.08, 3.16	0.681
通义千问 Plus	2.48, 1.46, 2.46, 2.31, 2.64	0.692
DeepSeek-Chat	2.67, 1.84, 2.77, 2.78, 2.94	0.670
豆包 Pro	2.76, 1.90, 3.25, 2.54, 3.28	0.844




图 1 各模型价值倾向雷达图

雷达图展示了各模型在五个价值维度上的整体倾向。GLM-4-Flash 表现较均衡，在“人类 vs 生态”和“技术 vs 预防”上略高；豆包-Pro 在“公平 vs 效率”和“技术 vs 预防”上得分最高；通义千问-Plus 整体偏低，尤其在“短期 vs 长期”维度较弱。




图 2 各模型地区偏移分布箱线图

图 2 反映了不同地区版本相对默认版本的评分偏移。多数模型在“经济 vs 环保”和“短期 vs 长期”上的偏移较小，说明地区影响有限；而“公平 vs 效率”“人类 vs 生态”“技术 vs 预防”波动更明显，表明这些维度更容易受到地区语境影响。

图 3 直观比较了各模型在五个维度上的平均评分。整体看，各模型在“短期 vs

长期”维度得分普遍最低，说明更偏向短期利益；“技术 vs 预防”和“公平 vs 效率”区分度较高。豆包-Pro 和 GLM-4-Flash 部分维度超过中立线，表现更积极。




图 3 各模型在不同价值维度上的平均评分柱状图

3.4 伦理设计

伦理设计主要体现在透明性、公平性、可问责性和责任边界。透明性方面，评估维度、题库、评分 Prompt、模型回答和结果均可追溯；公平性方面，地区变体用于显式检测不同地区语境下的系统性差异；可问责性方面，系统保留原始回答和评分理由，便于人工复核；责任边界方面，报告说明结果仅供课程学习和研究参考，不能替代政策判断或现实治理决策。

四、系统使用说明

github 仓库链接为 <https://github.com/hanys321/EnvAlign.git>。

运行环境建议为 Python 3.10 及以上。进入 EnvAlign 目录后，执行 `pip install -r requirements.txt` 安装依赖；复制 `.env.example` 为 `.env`，并填入至少一个模型平台的 API Key。

表 4 项目系统评测指令说明表

命令	作用
<code>python main.py eval</code>	调用被测模型生成回答

python main.py score	使用 Judge 模型进行五维评分
python main.py bias	计算地区偏见报告
python main.py report	生成 HTML 报告和可视化图表
python main.py all --max-questions 5	快速执行 5 题测试流程
streamlit run app.py	启动交互式仪表盘查看结果

当前项目已完成一次全量运行：50 道题 × 4 个地区变体 × 4 个模型，共 800 条回答和 800 条评分记录，结果位于 results 目录。使用者可查看 results/report.html，也可启动仪表盘筛选模型、地区和题目，查看平均评分、雷达图、偏见指标和原始回答。


五、初步使用反馈

通过对 20 名以上同学或潜在使用者试用系统，观察其能否独立完成报告查看、模型筛选、原始回答浏览和结果解释。调研方式采用匿名问卷。

表 5 重点问题回答（请对 EnvAlign 项目理解与伦理主题契合度作出评价）

题目\选项	很不同意	不同意	一般	同意	很同意
我能理解 EnvAlign 主要是在评估大模型环境政策建议中的价值倾向	0(0%)	0(0%)	4(19.05%)	9(42.86%)	8(38.1%)
我认为该项目符合 AI 伦理、算法偏见、透明性或 AI 治理相关主题	0(0%)	0(0%)	3(14.29%)	11(52.38%)	7(33.33%)
我认为用环境政策两难问题评估大模型价值倾向合理	0(0%)	1(4.76%)	6(28.57%)	7(33.33%)	7(33.33%)
我认为该系统能够体现负责任 AI 或科技向善设计思路	0(0%)	1(4.76%)	6(28.57%)	9(42.86%)	5(23.81%)

从受访者背景来看，计算机/人工智能/软件工程相关专业占比最高（61.9%），其次为环境科学/公共管理/政策研究方向（19.05%），样本具有较好的学科覆盖性。在对大语言模型的了解程度上，整体 AI 素养水平较高，具备对系统进行有效评价的基础能力。从开放性反馈的词云结果来看，系统在主题契合度和结果呈现方式上获得了初步认可。



在功能期望方面，多选题结果显示受访者最迫切的需求集中在三个方向：增加更多地区或群体变体以检测偏见（61.9%）、引入人工评分对照或人工复核机制（57.14%）、增加一键导出 PDF/Word 报告功能（47.62%）。此外，42.86%的受访者希望增加更多被测模型和提供更详细的评分解释，反映出当前系统在评估覆盖度和评分透明度方面仍有提升空间。综合来看，EnvAlign 后续改进应优先从三个方面着手：一是丰富评估覆盖面，二是增强评分的可解释性，三是完善输出形式，以进一步提升系统在非专业用户群体中的可用性和可信度。

EnvAlign 是一个面向大语言模型环境政策价值对齐的评估系统。系统围绕经济发展、生态保护、社会公平等五个伦理维度，设计了包含地区变体（北京、河北、西部地区等）的环境政策两难题库，通过 LLM-as-Judge 机制对多个主流大模型的回答进行自动评分，输出评估报告。初步用户调研显示，受访者普遍认可系统在模型价值倾向量化分析和偏见检测方面的创新性与实用性，同时建议后续在评估覆盖面、评分可解释性和报告导出功能方面进一步完善。

七、AI 使用声明

本文在撰写过程中仅使用人工智能工具进行语言润色、数据整理和图表分析辅助，核心项目设计、系统实现与结论判断由作者完成。