

EnvAlign 大语言模型环境政策价值对齐评估系统试用初步 反馈报告

本次针对 EnvAlign 系统开展试用调研，共回收有效问卷 21 份。受访人群以其他理工科背景为主，占比 61.9%，近七成受访者有使用生成式 AI 的经验，对大模型具备基础认知。试用形式上，近半数用户主要查看 HTML 报告与结果图表，多数人浏览时长集中在 5-10 分钟。

整体而言，用户对系统整体评价较好。大家普遍认可项目定位，认为系统贴合 AI 伦理、科技向善等主题，题库具备真实政策两难属性，区域变体设计可有效检测模型偏见。系统的评分规则、各类可视化图表、报告排版及交互功能清晰易懂，可用性表现良好。本次调研推荐意愿平均分达 4.05 分，多数用户愿意将该系统作为大模型价值评估工具及 AI 伦理课程展示素材。

调研也梳理出多项优化方向。在机制层面，超八成受访者认为必须增设人工复核环节，以此提升自动评分的可靠性。改进优先级排序显示，提高评分可信度、扩充题库是当前最核心的优化需求。功能拓展上，用户希望增加地区测试样本、人工评分对照、报告导出等功能。展示形式方面，在线网页链接是大家最认可的报告分发方式。

此外，部分用户提出系统专业术语、评分计算标准、图表图例缺乏详细注释，理解存在障碍。后续需补充内容释义，完善文档说明，持续优化系统实用性与专业性。